Plano de Desenvolvimento

Curso: Bacharelado em Ciência e Tecnologia	
Semestre: 5º	**Turma: 2025**
Professor(a): James Moraes de Almeida	
Disciplina: Processamento de Linguagem Natural e de Imagens	**C/H Semestral: 80**

Ementa da Disciplina

Processamento de linguagem natural e processamento de imagens

Conteúdo a ser ensinado
Detalhar como os tópicos da ementa serão abordados

Processamento de linguagem natural:
- Mineração de dados textuais e construção de corpora científicos.
- Tokenização, normalização, lematização e remoção de palavras vazias.
- Vetorização de textos: Bag-of-Words, TF-IDF e similaridade de cossenos.
- Vetores de palavras (word embeddings) e busca semântica.
- Extração de informações de texto com expressões regulares.
- Classificação de texto e modelagem de tópicos.
- Modelos de sequência e a arquitetura Transformer.
- Grandes modelos de linguagem aplicados à extração de dados científicos.

Processamento de imagens:
- Formação e representação de imagens digitais.
- Filtros de imagens e realce.
- Transformadas em imagens.
- Segmentação de imagens: limiarização e métodos automáticos.
- Segmentação com aprendizado de máquina supervisionado e não supervisionado.
- Análise quantitativa de imagens de microscopia.
- Redes neurais convolucionais para análise de imagens.

Objetivo(s) geral e específico(s)
Apontar claramente os objetivos a serem alcançados e que possam ser mensurados

Objetivo geral:
Levar os estudantes ao aprendizado dos fundamentos de processamento de linguagem natural e de processamento de imagens, capacitando-os a aplicar essas técnicas a dados reais de pesquisa em ciência e tecnologia.

Objetivos específicos:
- Construir e preparar corpora de texto a partir de bases bibliográficas, aplicando tokenização, lematização e demais etapas de pré-processamento.
- Representar textos como vetores por meio de Bag-of-Words, TF-IDF e embeddings, e medir a similaridade entre documentos.
- Extrair informações estruturadas de textos científicos, empregando expressões regulares e grandes modelos de linguagem.
- Explicar o funcionamento dos modelos de sequência e da arquitetura Transformer, reconhecendo suas vantagens sobre as representações anteriores.
- Manipular imagens digitais, aplicando filtros e transformadas para realce e extração de características.
- Segmentar imagens por limiarização e por aprendizado de máquina, quantificando as estruturas de interesse.
- Empregar redes neurais convolucionais na classificação e na segmentação de imagens científicas.

Metodologia

Descrever em detalhes as estratégias e dinâmicas de ensinagem a serem desenvolvidas, privilegiando, com base no Modelo Ilum, a aprendizagem ativa.

A metodologia empregada será ativa, com pequenas explanações expositivas no início da aula, para apresentar o problema a ser resolvido. Após isso, os estudantes resolverão o problema proposto em cadernos computacionais (notebooks) preparados para a disciplina, que alternam explicação, código comentado e exercícios.

O docente deve acompanhar o desenvolvimento das atividades, sendo algumas realizadas em grupos e outras individuais. Os problemas propostos partem de dados reais de pesquisa, de modo que os estudantes percebam a aplicação direta das técnicas ao seu próprio contexto científico.

Recursos Utilizados

Relatar o uso das TICs (vídeos, podcast, simulações etc.) tanto em sala de aula como nas plataformas Teams e Moodle

Computadores dos estudantes, plataforma Teams, vídeos do YouTube e recursos de computação científica da Ilum.

Cadernos computacionais (Jupyter/Google Colab) elaborados para a disciplina, empregando as bibliotecas spaCy, scikit-learn, Gensim, scikit-image, OpenCV e bibliotecas de aprendizado profundo.

Conjuntos de dados reais: exportações de bases bibliográficas para as aulas de linguagem natural e imagens de microscopia para as aulas de imagens.

IlumA: Servidor de LLM da Ilum, a IlumA será utilizada em códigos Python via API (iluma.cnpem.br:4000). Isso possibilitará a extração de dados da literatura científica ou construção de códigos que intergrem IA.

Avaliação

Dar ênfase na avaliação formativa em sala de aula
A avaliação somativa será na forma de relatórios redigidos em sala de aula, com o acompanhamento do docente. Assim, o docente poderá aliar a avaliação formativa à somativa, ao conduzir a elaboração dos relatórios, tirando dúvidas e direcionando o trabalho, além de notar as dinâmicas dos grupos e o interesse dos estudantes individualmente. **Os relatórios são elaborados em duplas e avaliados por conceitos, considerando a correção da solução implementada, a interpretação dos resultados obtidos e a clareza da argumentação.**

Referências Bibliográficas
- Speech and Language Processing, Daniel Jurafsky e James H. Martin, 3ª edição (rascunho aberto). **- Practical Natural Language Processing, Sowmya Vajjala, Bodhisattwa Majumder, Anuj Gupta e Harshit Surana, O'Reilly Media, 2020.** **- Digital Image Processing, Rafael C. Gonzalez e Richard E. Woods, Pearson, 4ª edição, 2018.** **- Programming Computer Vision with Python, Jan Erik Solem, O'Reilly Media, 2012.** **- Natural Language Processing Succinctly, Joseph D. Booth, Syncfusion, 2018.** **- NLP Demystified, Nitin Punjabi (curso aberto): https://nlpdemystified.org** **- Python for Microscopists, Sreenivas Bhattiprolu (canal DigitalSreeni).**

Observação(ões)